文档倒排索引

一、 实验设计

参考教学 ppt 及书上示例代码,文档倒排索引主要设计以下函数:

Mapper 函数:

由于此次倒排索引需要携带词频属性,因此在从文件中获取 token 之后,需要添加 filename 来共同作为键值对中的 key。Token 与 filename 之间以#相连,组成的 key 为 text 类型。在 map 阶段,每次生成的 key 其 value 值均为 1,类型为 IntWritable。

```
private static final IntWritable one = new IntWritable(1);
private Text word = new Text();

StringTokenizer tokenizer = new StringTokenizer(value.toString().toLowerCase());
while (tokenizer.hasMoreTokens()) {
    word.set(tokenizer.nextToken() + "#" + fileName);
    context.write(word, one);
}
```

Combiner 函数:

Mapper 输出的中间结果中会包含大量相同主键的键值对,combiner 将 mapper 输出的中间结果中的词频进行累加,来减少向 reduce 节点中传输的数据量。

```
int sum = 0;
for (IntWritable val : values)
    sum += val.get();
result.set(sum);
    context.write(key, result);
```

Partitioner 函数:

由于我们的 key 是 token#filename 的形式,但我们是想对 token 进行词频统计。为了保证具有相同 token 的键值对可以分配到相同的 reduce 节点,因此需要暂时将 key(token#filename)进行拆分。

```
public int getPartition(Text key, IntWritable value, int numReduceTasks) {
    String term = key.toString().split("#")[0];
    return super.getPartition(new Text(term), value, numReduceTasks);
}
```

Reducer 函数:

Reducer 从 patitioner 拿到键值对后,需要对相同 token 在不同 file 中的计数进行叠加。因此此时我们需要把原本的 key(word#filename)进行拆分,k-v 由 word#filename – sum 转化为 word – filename: sum。在这部分我们使用 lastword 来记录上一个处理的 token,curword 记录当前处理的 token,维护一个 string 类型的队列 postingList 来保存相同 token 的文件:词频信息(即保存内容为 filename: sum 的字符串),当某一 token 处

理完成时,list 的大小即为包含此 token 的文件数,然后将此 list 清空,然后用来继续保存下一个 token 的信息。

```
String[] keyPair = key.toString().split("#");
curWord.set(keyPair[0]);
String fileName = keyPair[1];
int sum = 0;
for (IntWritable val : values)
    sum += val.get();
if (!lastWord.equals(curWord) && !postingList.isEmpty())// 当前token 与上一个不同,即上
一个 token 已处理完毕
    commitResult(context); //自定义函数, 详见下
postingList.add(fileName + ": " + sum);
totalCount += sum;
lastWord.set(keyPair[0]);
private void commitResult(Context context) //自定义函数
               throws IOException, InterruptedException {
   StringBuilder builder = new StringBuilder();
   builder.append(totalCount / (double) postingList.size()); //平均词频
   builder.append(", ");
   \quad \textbf{for} \ (\texttt{String str} \ : \ \mathsf{postingList}) \ \{
        builder.append(str); //写入 filename: sum
        builder.append("; ");
   context.write(lastWord, new Text(builder.toString()));
   totalCount = 0; //清空, 开始计算下一token
   postingList.clear();
```

二、 运行截图

集群上执行 InvertedIndex 程序指令:

hadoop jar mapreduce-lab.jar inverted_index.InvertedIndex /data/wuxia_novels output 其输出内容前半部分:

```
To the state of th
```

mapreduce.JobSubmitter: Submitting tokens for job: job_1508726229114_0262
impl.YarnClientImpl: Submitted application application_1508726229114_0262

集群中输出文件的位置在\$HOME/lab2 中, Hdfs 下的路径即在 inverted-index-output 文件夹下

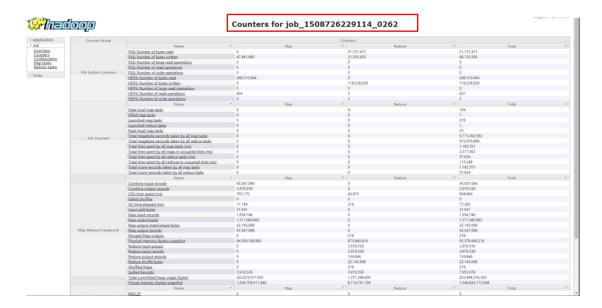
```
[2017st29@master01 lab2]$ ll
total 246168
-rw-r--r-- 1 2017st29 hadoop_user 118238028 Nov | 1 19:56 count-sort-result.txt
-rw-r--r-- 1 2017st29 hadoop_user 8587 Oct 28 22:24 fileList.txt
 rw-r--r-- 1 2017st29 hadoop_user
[2017st29@master01 lab2]$ hdfs dfs -ls
.
17/11/01 20:24:14 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your plat
Found 4 items
                                     drwxr-xr-x - 2017st29 hadoop_user
-rw-r--r-- 3 2017st29 hadoop_user
drwxr-xr-x - 2017st29 hadoop_user
drwxr-xr-x - 2017st29 hadoop_user
                                        9 2017-11-01 20:08 inverted-index-output
                                         2017-11-01 20:10 tf-idf-output
[2017st29@master01 lab2]$
    st29@master01 ~]$ hdfs dfs -ls inverted-index-output
17/11/01 19:52:30 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... usi
Found 2 items
```

以"江湖"、"风雪"两个单词为例,它们的输出结果为(部分):

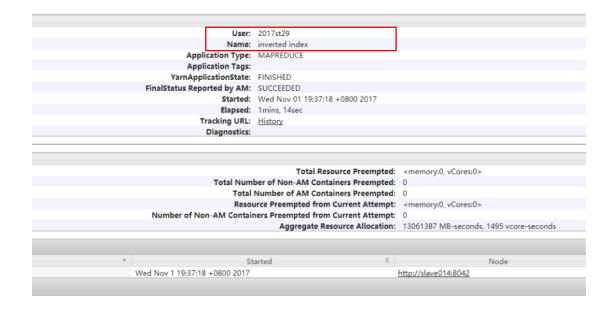
```
[2017st29@master01 lab2]$ grep "^\(init) [风雪\)" inverted-index-result.txt
正謂 116,06481481481481481481481481481481. 卧龙生01. 禮獎: 275; 卧龙生02. 誊秋笔: 329; 卧龙生03. 聚袖玉环: 402; 卧龙生04.地球门: 105; 双矫: 117; 卧龙生12.剑气调彻九重天: 299; 卧龙生13.剑无痕: 261; 卧龙生14.剑仙列传: 25; 卧龙生15.络雪玄霜: 274; 卧龙生14.剑仙列传: 25; 卧龙生15.络雪玄霜: 274; 卧龙生34.天龙甲: 293; 卧龙生35.天与霜衣: 278; 卧龙生30,天香纸: 246; 卧龙生37.天涯情侣: 113; 卧龙生38. 缺剑玉痕: 71; 子传奇: 132; 卧龙生46.指花放鹰传: 446; 卧龙生47.一代天部: 353; 卧龙生48.根月飞霜: 132; 卧龙生49. 迪灵四艳: 221; 卧龙生30. 表音机: 880; 古龙15.44. 无龙曾 49. 迪灵四艳: 221; 卧龙生30. 表音机: 880; 古龙25. 水东英雄: 64; 古龙26. 法花沙8. 无容34; 880; 古龙26. 法花传6. 81; 古龙26. 法花沙8. 无容34; 880; 古龙27. 血鳞路: 11; 古龙28. 纵东英雄: 64; 古龙26. 法花沙8. 无容34; 880; 古龙27. 大连寄卷66. 张环曲: 76; 古龙67. 决金长五8. 82; 古龙80. 无容34; 880; 古龙27. 大英雪谷66. 张天英雄: 64; 古龙26. 法花沙8. 无容34; 880; 古龙27. 大连寄卷66. 大英强高-12. 大连节整个型。 153; 古龙25. 水东英雄: 64; 古龙26. 法花光剑录: 285; 古龙27. 血鳞路: 11; 古龙28. 纵东水园高-12; 18; 古龙29. 剑毒梅香: 193; 古龙25. 水东英雄: 64; 古龙26. 法花光剑录: 285; 古龙27. 血鳞路: 11; 古龙28. 纵东水园高-12; 18; 七龙29. 剑毒梅香: 137. 流星-蝴娥绿. 91; 32; 古龙47. 怒剑狂花: 102; 古龙48. 飘香剑雨: 66; 古龙49. 七杀手; 20; 古龙50. 七星龙王: 55; 古龙50. 七龙69. 圆月弯刀: 155; 古龙70. 月异星邪: 102; 李凉01. 暗器高手: 93; 李凉26.奇神奇外帝群勃份作: 12; 古龙61. 朱线$19; 65; 古龙69. 圆月弯刀: 155; 古龙70. 月异星邪: 102; 李凉31. 暗器高手: 93; 李凉32. 黄岭24. 沙岭了小山线集: 13; 李凉32. 少岭的34. 北湖双鸣烛: 291; 李凉15. 江湖一担皮: 197; 李凉16. 龙69; 四月万分。 大香沙25. 改树了小鸡菜。 189; 李凉26. 奇神奇外小宗线集: 98; 李凉27. 今神杨小宗; 李凉35. 武林灌游记: 189; 李凉36. 小鬼大海宫: 189; 李凉36. 小鬼大海宫: 189; 李凉36. 小鬼大海宫: 189; 李凉36. 小鬼大海宫: 189; 李凉36. 大春岭(4); 李汉32. 少岭市332. 北湖平坦29; 李凉39. 新蚕31. 刘徐传: 2; 全60; 128; 梁羽生17. 江湖三女长; 189; 李凉36. 大春岭(4); 平汉32. 北京338; 189; 李凉36. 大春岭(4); 李汉32. 北京338; 189; 李凉36. 大寿岭(4); 李凉36. 大寿岭(4); 李汉32. 北京32. 朱泉梁32. 北京338; 189; 李凉36. 大寿岭(4); 李汉32. 北京32. 北京32.
```

江湖 116.06481481481481, 卧龙生01. 腰旗: 275; 卧龙生02.春秋笔: 329; 双娇: 117; 卧龙生12.剑气洞彻九重天: 299; 卧龙生13.剑无痕: 261; 卧龙生捕头: 317; 卧龙生23.飘花令: 263; 卧龙生24.七绝剑: 130; 卧龙生25.七绝约

Mapreduce Job 执行截图:



Application application_1508726229114_0262



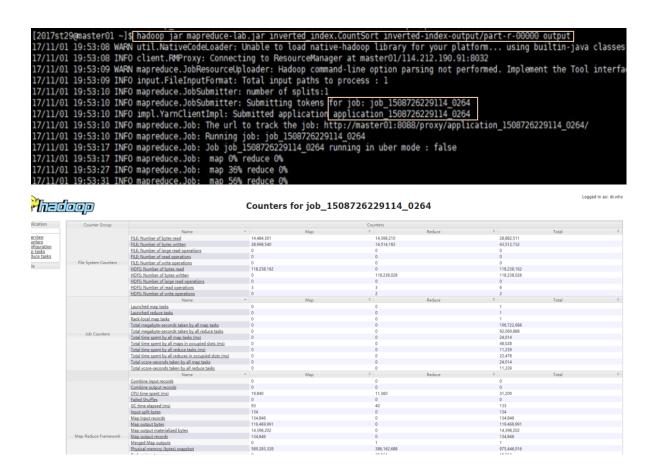
选做题:

两道选做题均以上述倒排索引算法的输出作为输入文件,代码以一并打包入 mapreduce-lab.jar 中。其集群本地输出文件与 hdfs 输出路径与倒排算法相同,在上面的 路径截图的虚线框中体现。

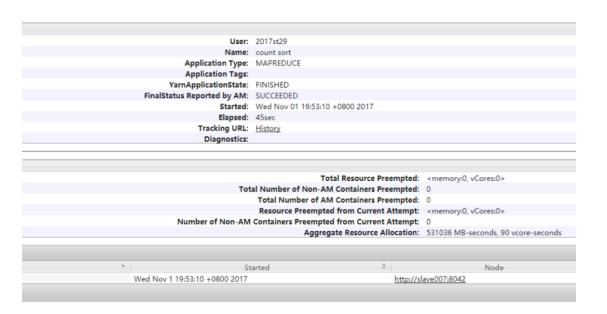
对每个词语的平均出现次数全局排序算法的执行命令为:

hadoop jar mapreduce-lab.jar inverted_index.CountSort inverted-index-output/part-r-00000 output

其执行截图如下:



Application application_1508726229114_0264



对每位作家,计算每个词语的 TF-IDF 算法的执行语句为:

hadoop jar mapreduce-lab.jar inverted_index.Tfldf fileList.txt inverted-index-output/part-r-00000 output

其执行截图如下:

```
[2017st29@master01 | dD21$ haddoop jar mapreduce-lab.jar inverted_index.ffIdf fileList.txt inverted_index-output/part-r-00000 output]
17/11/01 20:09:27 WARN util.NativeCodeLoader: Unable to load native-haddoop library for your platform... using builtin-java classes where a
17/11/01 20:09:28 INFO client.RNProxy: Connecting to ResourceManager at master01/114.212.190.91:8032
17/11/01 20:09:29 WARN mapreduce.JobResourceUploader: Haddoop command-line option parsing not performed. Implement the Tool interface and e
17/11/01 20:09:29 INFO input.FileInputFormat: Total input paths to process: 1
17/11/01 20:09:29 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1508726229114_0266
17/11/01 20:09:30 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1508726229114_0266
17/11/01 20:09:30 INFO impl.YarnClientImpl: Submitted application application_1508726229114_0266
17/11/01 20:09:30 INFO mapreduce.Job: The url to track the job: http://master01:8088/proxy/application_1508726229114_0266/
17/11/01 20:09:30 INFO mapreduce.Job: Bub job_1508726229114_0266 running in uber mode: false
17/11/01 20:09:36 INFO mapreduce.Job: map 0% reduce 0%
17/11/01 20:09:50 INFO mapreduce.Job: map 23% reduce 0%
17/11/01 20:09:50 INFO mapreduce.Job: map 39% reduce 0%
17/11/01 20:09:53 INFO mapreduce.Job: map 39% reduce 0%
```



Application application_1508726229114_0266

